

# 北京厚笃科技

## 业务介绍

● 致力于成为国内头部数字化基础软件的技术与服务提供商



**厚笃科技**成立于2023年11月，起源于清华大学计算机系院士团队，核心成员主要来自清华大学计算机系高性能所和中国科学院自动化所，以海量数据一站式处理的国产化硬核技术为基础，构建极致性能的大数据处理引擎、大数据+AI统一编译技术、安全高效的数据开发平台等**大数据产品体系**，**支撑大数据AI的一体化应用**，同时打造以数字底座为核心的**场景化解决方案**，深耕国产化数字底座的行业落地。



# 背景：数据技术的演变

Table: customers

| customer_id | first_name | last_name | phone        | country |
|-------------|------------|-----------|--------------|---------|
| 1           | John       | Doe       | 817-646-8833 | USA     |
| 2           | Robert     | Luna      | 412-862-0502 | USA     |
| 3           | David      | Robinson  | 208-340-7906 | UK      |
| 4           | John       | Reinhardt | 307-242-6285 | UK      |
| 5           | Betty      | Taylor    | 806-749-2958 | UAE     |



- 2018年 Transformer 发布
- **数据处理**的类型、规模、计算方式都发生了深刻变化
- Data for AI、AI for Data
- 尚未出现引领性技术

- 1970年关系型数据库发布
- **解决结构化数据的存算问题**
- 以事务数据处理技术为核心
- 底层技术：Oracle, SQL Server, 达梦

- 2000年左右由Google提出
- **解决大规模数据的分布式存算问题**
- 支持灵活数据模式、复杂分析任务
- 以Hadoop、Spark为核心，发展出一套丰富生态体系

数据库革命


大数据革命

AI革命

量变与质变

以数据融合为中心  
以AI为终点

以指标体系为中心  
以BI为终点




# AI时代的数据技术需求

## 能力需求



- 涉及到大量非结构化、半结构化数据，例如网页、文档、图片、视频等
- 不适合关系型数据库的表达和处理
- 需要支持异构硬件

## 性能需求



- 随着技术发展和数据处理能力的提升，需要的数据处理规模急剧扩大
- AI任务经常需要处理高达PB级别的原始数据，处理时间长、成本高昂

## 多种数据模态

## 需求与挑战

## 超大数据规模

## AI管线融合

## 智能需求



- Data for AI: 为AI模型或知识库准备数据
- AI for Data: 在数据处理过程中应用AI能力，或利用AI完成数据价值挖掘

# 做被广泛使用的国产化数据+AI基础软件

前沿高性能技术路线 + AI生态能力

技术来源于清华大学计算机系，自主可控

## 更快速

- **高性能大数据引擎（诸葛弩）**：精心调优的高性能算法；加速比可以5倍以上，降本增效

## 更好用

- **Data+AI统一编译优化**：自动编译，实现低门槛、高性能能力
- **统一数据开发平台**：一站式数据处理的数据管线；开箱即用的高性能算子；多模态数据处理

## 更智能

- **Data for AI, AI for Data**；灵活取数问数，释放数据价值



坚持以**Data+AI**为落脚点，提供全栈式数据“采管算用”一体化的硬核科技

## 场景服务

数字校园

数字乡村

其他.....

私域知识库

AI问数

提供智能私域大模型，针对数字校园、数字乡村、汽车营销、国际贸易等领域提供相应的AI智能体产品以及应用。

## 数据服务

高质量数据集生产服务

数据管线性能加速服务

基于自研软件性能优势、硬件规模优势、交付经验优势，面向海量数据处理的场景，提供端到端的数据服务。

## 平台服务

通用数据开发

语料数据开发

湖仓一体平台

为多种模态数据提供一站式管理和开发能力的平台，降低大数据开发应用、大模型语料开发管理和运维的难度。

## 基础软件

统一编程模型与编译优化

诸葛弩高性能计算引擎

厚笃自研高性能计算引擎，为上层提供高性能计算加速、大数据与AI的统一编程框架、CPU+GPU混合计算框架等。

01

# 基础软件

国产化、高性能、易使用



# 更快速：自研高性能多模态数据引擎诸葛弩



SQL、Structured Streaming、DataFrame、Pandas等前端接口

自研关系型计算引擎

高效算子实现

代码生成与向量化

基于规则的优化

自研RDD编程框架

Native执行

算子融合

向量化

分布式运行时模块

历史服务器

作业提交

调度器

故障恢复

资源管理

运行状态监控

远程过程调用

负载均衡

## 极致效率

在C++的高性能原生算子的基础上，进一步进行数据处理领域专用的编译优化，在常见应用中较Apache Spark获得数倍至数十倍加速比。

## 支持 Spark 编程接口

支持Spark编程接口，具备同等容错、调度、资源管理能力，用户切换成本低，无缝提升性能。

## GPU+CPU混合处理

高效的GPU调用，极大便利数据处理与AI推理融合应用。

## 兼容开源生态

兼容Hadoop、Iceberg、AirFlow等海量开源生态，可以与用户的存量基础设施轻松衔接。

## 云原生




支持容器化部署，存算分离、弹性扩展，降本增效。

# ● 技术亮点：极致性能




## 非结构化数据处理、图计算、机器学习

同样计算资源、同样数据量、进行同样算法计算，诸葛弩计算时间仅为几分之一到几十分之一。




## 文本数据去重 MinHash算法

无需对原PySpark代码进行任何修改，获得1.6倍加速比；进行少量改写，获得2.5倍加速比



## 基于SQL的结构化数据分析

在1TB数据规模下，完整支持TPC-DS的99个查询，平均加速比3倍



# ● 技术亮点：CPU+GPU混合的多模态数据处理



- 允许用户灵活调用CPU/GPU混合负载的UDF，进行复杂的自定义数据处理
- 实现了大数据处理系统对高效异构硬件的支持，扩展了大数据处理的能力边界

无需新增系统  
原地GPU调用效率**6倍**提升

```
1 @chukonu_udf(batch_format="numpy", num_cpus=1)
2 def preprocess(image_batch: Dict[str, np.ndarray]) -> Dict[str, np.ndarray]:
3     preprocess = transforms.Compose(
4         [
5             transforms.Resize(256),
6             transforms.CenterCrop(224),
7             transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]),
8         ]
9     )
10    torch_tensor = torch.Tensor(image_batch["image"].transpose(0, 3, 1, 2))
11    preprocessed_images = preprocess(torch_tensor).numpy()
12    return {"image": preprocessed_images}
13
14 @chukonu_actor(batch_size=1000, num_gpus=1, batch_format="numpy", max_concurrency=2)
15 class predict:
16     def __init__(self):
17         self.model = model.value()
18         self.model.to("cuda")
19
20     def __call__(self, batch: Dict[str, np.ndarray]):
21         with torch.inference_mode():
22             output = self.model(torch.as_tensor(batch["image"], device="cuda"))
23             return {"output": output.cpu().numpy()}
24
25 spark.read.format("parquet")
26 .load("s3a://houdu-air-example-data-2/10G-image-data-synthetic-raw-parquet")
27 .select(preprocess(col("image")))
28 .select(predict(col("preprocess(image)")))
29 .write.mode("overwrite").format("noop").save()
```

诸葛弩调用GPU方法示例

**支持多卡调用 1.5X**

充分利用资源，提升  
并行能力和扩展性

**数据优化 3.5X**

数据结构加速处理，  
减少数据转换开销

**Per-Stage资源控制 2.8X**

应对数据处理全流程  
的负载变化

**任务调度与重叠 6.0X**


资源感知的任务调度，  
计算和通信流水线重叠

# ● 技术亮点：Data+AI统一编译技术



研发 Python UDF优化器，实现Python UDF到高性能C++实现的自动编译，实现低门槛、高性能。

- 将Python UDF转换为基于MLIR的中间表示，同时再施加一系列优化（元数据透传、case when分支裁剪、Native编译等），最后转换为Catalyst的一个表达式并交由Catalyst进行后续优化。



02

## 数据平台

一体化、可视化、智能化

## 弹性扩展


- 支持k8s、enroot等主流容器平台，按需申请、弹性扩展，资源高效利用

## 存算分离

- 支持存算分离架构，计算和存储资源按需独立扩缩容，降本增效


## 快速部署

- 流程化部署，快速高效





通过低门槛操作、标准化配置、智能化支持，帮助用户高效完成数据价值挖掘



一体化

- 平台涵盖从数据的汇聚、管理到开发、应用的全生命周期流转能力
- 采用湖仓一体底层架构，实现结构化数据、非结构化数据、AI模型的统一管理和应用



可视化

- 界面化操作低门槛完成各类数据治理工作，自定义编码能力保证灵活性
- 可视化数据开发和任务编排，兼容多个计算引擎，无感应用诸葛弩



智能化

- 预设高性能算法节点，可快速搭建机器学习或文本语料数据处理管线
- 数据开发流程无缝衔接大模型知识库，支撑新一代BI与AI融合的数据应用



# 灵活的高质量语料数据生产能力



## ● 文本数据处理基础能力

- 文本清洗、语种识别、质量打分等**六十余种算子**
- 无代码设计，仅需进行算子参数配置
- 支持自定义数据输入算子、自定义清洗算子，灵活编程，满足定制化处理需求

## ● PDF 解析

- 高效解析电子书、论文、公文等各种体裁
- 融合OCR、大模型等技术，解析效果准确

## ● Common Crawl 处理管线

- 针对开源网页数据集的处理管线
- 产出高质量结果，显著提升模型质量



## 公有云

- 将厚笃的产品集成到公有云的应用市场，用户无需搭建自己的基础设施，即可云上体验。



诸葛弩已上架亚马逊AWS MarketPlace，作为云主机插件。后续将推出数据开发SaaS平台，面向全球服务。

### AWS 优势

- 技术兼容性强，加快部署和交易进度
- MarketPlace 模式成熟，有利于规模化复制
- 全球覆盖广泛，为出海打下基础
- 借助AWS的市场活动和机制进行推广

## 私有云

- 与信创云、政务云合作，补充私有云软件生态，充分发挥国产硬件和操作系统的性能潜力。



厚笃大数据开发平台入选首信云（北京市政务云运营方）、移动云等合作伙伴供应清单。

- 智算云，Data+AI一体化部署，提升全流程处理能力。



温州市数据集团有限公司  
WENZHOU DATA GROUP CO.,LTD

厚笃科技是温州市智算中心合建单位，承接数据处理基础平台建设，扩展智算平台能力边界。

# ● 适用的技术场景




面向**大模型训练的文本语料清洗库**，支持文本语料数据的正文提取、过滤、去重等功能

面向**自动驾驶、具身智能的多模态数据**高性能处理能力，对异构硬件的高效支持

面向**海量超大规模数据集的机器学习库**，提供了K-Means、LR等传统机器学习算法

对**低空飞行、卫星等大规模行业数据**的高性能处理

**处理海量超大规模图数据**，提供了高性能的PageRank等图计算算法




# ● 场景一 赋能大模型团队高质量数据生产

Houdu




## 加速场景一：PDF解析

- 提供端到端PDF解析服务，保证解析结果一致，硬件资源利用率翻倍，2倍以上加速比




## 加速场景二：正则表达式匹配

- 通过编译优化技术，重构正则表达式的转换器、解释器，提升执行和匹配效率，2倍以上加速比




## 加速场景三：数据集去重

- 基于MinHash算法的数据集去重实现，减少数据集中的重复内容，2倍以上加速比



万核  
CPU



数千万  
年成本



关键任务运行时间减少 **50%+**

相应计算成本减少 **50%+**

代表案例：头部大模型创业公司、国央企大模型团队、知名高校与科研院所

## ● 场景二 赋能自动驾驶异构混合数据处理

### 数据多样

- 数据格式多样
- 数据解析流程缺乏统一标准

### 关联复杂

- 数据形态复杂
- 需要跨模态数据关联，保证一致性

### 运维困难

- 任务依赖手工编排，运维困难
- 执行过程不可追踪，故障后难以恢复

### 计算昂贵

- 数据体量大，计算资源需求高
- 需要弹性计算框架和优化调度能力


灵活的数据处理和资源调度能力，但缺少GPU支持



擅长GPU调度，但编程模型和管理过于简陋



### 自动驾驶数据处理的痛点



### 诸葛弩

- 兼容Spark框架和开源组件，便捷管理和开发
- 支持GPU，提升多模态数据处理性能，降低处理成本

### 数据开发平台

- 解决多样化数据接入、组织和一致性关联问题
- 提供易用的一站式开发能力，提升协同效率

03

## 数据服务

高效、智能的端到端服务




## 示例：面向大语言模型训练或应用的数据集生产流程

### ● 面向场景

- 海量数据处理，资源消耗成本高，需要降本增效
- 涉及的数据和计算模式有一定的复杂性
- 验收标准明确

### ● 厚笃优势

- 软件优化提升性能
- 硬件资源规模效应
- 丰富经验交付迅速





# ● 场景一：助力汽车营销数据集治理和应用




数据来源

|                  |               |                  |              |                    |              |                       |              |              |                  |
|------------------|---------------|------------------|--------------|--------------------|--------------|-----------------------|--------------|--------------|------------------|
| 门户网站             | 搜索引擎          | 垂直论坛             | 视频网站         | 社交媒体               | 信息流APP       | 分发平台                  | 问答平台         | 电商点评         | 媒体报刊等            |
| 4000个<br>1985个首页 | 15个<br>百度、搜狗等 | 8000个<br>120万+频道 | 35个<br>优酷土豆等 | 双微API对接<br>KOL10万+ | 43个<br>今日头条等 | 6大平台含百家号等<br>5000+KOL | 12大平台<br>知乎等 | 22家<br>淘宝京东等 | 800+家<br>各大区域及海外 |

## 数据治理

- 数据汇集
- 分类打标
- 模型构建

有条理、有洞察的  
高质量数据体系



## AI加持

- 数据理解
- 智能问答
- 报告生成

报告、文案的交付  
成本降低2/3

04

## 场景服务

技术+场景双轮驱动



# Data+AI融合应用



## 为拥有大量私有化数据的领域客户提供从数据处理到业务Agent的融合解决方案



### 自然语言交互查询

准确理解用户意图，精确解析，结合私域数据进行回答



### 多样化私有数据统一管理

融合结构化数据和非结构化数据，对私域知识进行深度整合与管理




### 可视化图表分析

查询结果以直观的可视化形式呈现，帮助用户快速理解数据趋势




### 行业定制报表和报告生成

依据用户设定的行业标准和需求，生成专业行业报表和报告



# ● 基于AI知识库形成了AI 学科助手



个性化定制：教师可自主上传教材、习题、教学大纲等教学内容，也可上传专业教研论文打造私人科研助手

智能知识增强：基于RAG+Agent实现知识点自动关联与习题推荐

权限分级控制：支持教研组协同编辑知识库，设置公开/私有权限，满足校本化需求

跨端同步：PC端创建的知识库可同时在微信小程序使用，支持移动端碎片化学习和研究




多模态知识融合，结构化知识图谱，教研组协同编辑，赋能各门课程建设

# 场景一：某区县企业数据治理+智能化项目


服务

全域涉企数据治理关联



产品

语料数据全流程治理平台



应用

基于大模型的私域智能体

个性化数据需求



## 对话式数据查询


- 自然语言提出需求，智能体自动化查数
- 多轮交互，调整优化数据结果以满足需求

## 对话式数据分析

- 基于命题，开展取数、统计、分析、可视化工作
- 结合分析结果，自主给出总结或决策依据



## ● 场景二：AI赋能智慧教学，开启数理教育新范式




某211大学理学院携手前沿人工智能技术，成功构建覆盖“教学-管理-服务-分析”全链条的AI学科助手平台，实现四大核心突破：

- ✓ **智能点名，高效精准：**通过人脸识别与行为分析技术，实现课堂无感考勤，大幅减轻教师负担，提升课堂管理效率。
- ✓ **7×24小时AI答疑：**针对数学、物理等数理基础课及多门专业课程，部署专属AI学科助手，学生可随时提问，获得精准解答，显著提升学习自主性与问题解决效率。
- ✓ **知识图谱驱动智慧教学：**构建覆盖各学科的知识图谱与结构化知识库，打通AI与课程关联，支持自主学习与深度内容检索。
- ✓ **学情分析构建教学闭环：**统通过对学生提问数据的持续采集与分析，生成课程学情报告，助力教师精准把握学生学习难点，优化教学设计，实现“以学定教”的数据驱动型教学模式。



## ● 场景三：厚笃湖仓平台赋能数字乡村



数字乡村平台通过发挥大数据、物联网、云计算等科技力量，打破数据孤岛，实现了镇级全域数据的统一采集、管理，建立了镇域级数据底座，融合物联设备和AI算法，进行应急预警，最终通过GIS可视化大屏进行呈现，实现了“一屏看全域”的数据使用需求，为政务工作人员提供了直观、可靠的决策数据支持，帮助他们做出更为明智的决策。



厚笃科技承建的浙江省瑞安市曹村镇数字乡村项目，获得住建部和联合国评选的可持续发展最佳案例。



05

## 团队信息

数据重塑世界

# ● 公司成果



## 荣誉称号



## 知识产权



## 清华大学许可知识产权



## 厚笃科技自主申请知识产权

(已取得软著十余项，提交专利3项)

## ● 团队介绍



发起人



**郑纬民 院士**

首席科学家/中国工程院院士

长期从事并行/分布处理、大规模数据存储系统领域的科研与教学工作，深度参与我国超算中心、智算中心建设，承担多项国家重点研发工作。曾任中国计算机学会第十届理事长。曾获国家科技进步一等奖1次、国家科技进步二等奖2次，国家发明二等奖1次。

创始人



**陈文光 教授**

创始人/清华大学教授

清华大学计算机系教授。主要研究领域为操作系统、编译器与并行计算，国家自然科学基金杰出青年基金获得者。现为中国计算机学会会士，学术工委主任，YOCSEF荣誉委员；北京计算机学会副理事长；ACM中国理事会常务理事。曾任蚂蚁集团副总裁、技术研究院院长。

CEO

联合创始人



**林甲灶 博士**

CEO

曾任中科院自动化所助理研究员，曾在清华大学计算系、北京大学信息管理系从事博士后研究工作，曾担任威星智能[002849]首席科学家以及停划算共享停车平台的创始人。连续创业者，在物联网，大数据等方面领导或参与多个项目的建设，具备丰富的商业化经验。



**请您指导！**